Parallelisierung in Computer Vision

Grundlagen mit Implementierungsbeispielen

Christian Braun

18. Januar 2021

Motivation

ein kurzer Überblick

- Erste Sichtung von parallelisierbarer Lösungen
- Merkmale um die Parallelisierbarkeit einzuschätzen
- Mögliche Implementierungsbeispiele
- Probleme aus der Praxis

Konventationen bezüglich Computer Vision

Um eine gemeinsame Grundlage zu schaffen

- Abbildungsfunktionen können ein n-Tupel auf ein m-Tupel abbilden, mit n,m $\in \mathbb{N}$
- Ein Tupel besteht aus einer Matrix(c,r) von Pixeln, für die n = c*r gilt mit c,r $\in \mathbb{N}$& c,r ≥ 1
- Ein Pixel ist ein 3-wertiges Skalar welches die Farben in Reihenfolge Blau, Grün und Rot darstellt (BGR Farbraum)
- Ein (Kamera-)Bild ist eine Matrix(c,r)

Korrektur von Abbildungsfehlern

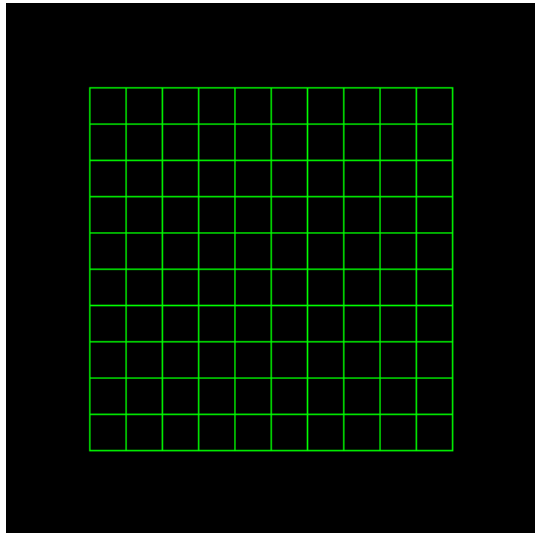

ohne Verzeichnung

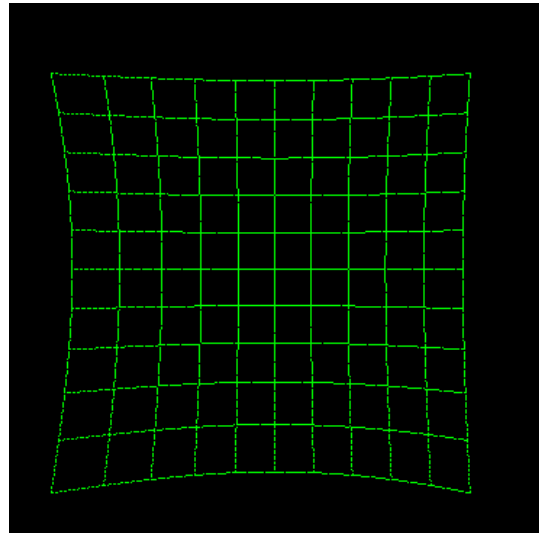

volle Verzeichnung

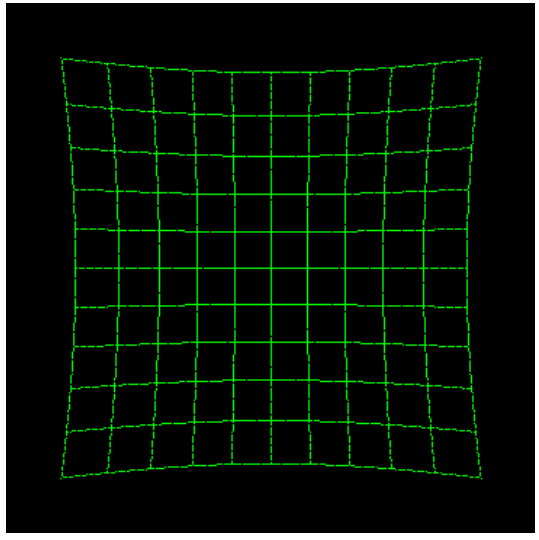

radiale Verzeichnung

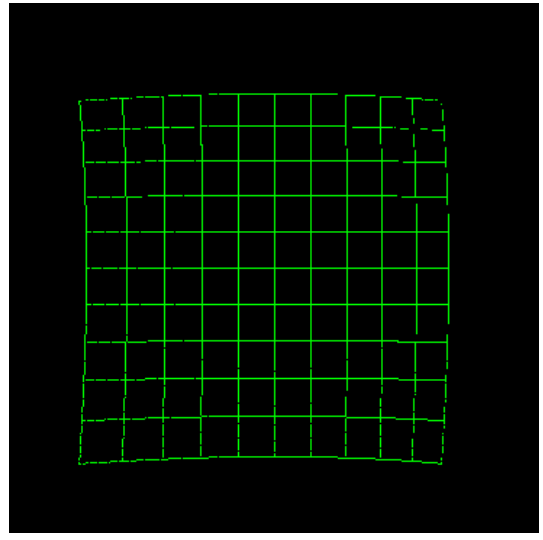

tangentielle Verzeichnung

Unterschiedliche Arten von Parallelisierung

Bei der Parallelisierung sind zwei Begebenheiten zu unterscheiden

- Datenparallelisierung - Aufteilen einer einzelnen Aufgabe
- Aufgabenparallelisierung - Aufteilen mehrerer von einander unabhängige Aufgaben

Ziel der Analyse

Bei der Aufteilung einer einzelnen Aufgabe

- weniger Synchronisierungaufwand
- Vermeidung der Notwendigkeit zur Absicherung
- Isolierung einer Aufgabe (divide and conquer)
- Kapselung für Fehlerfälle (Unhandled Exception)

Gegenüberstellung Platzproblem

Größe und Position vor und nach der Abbildung

Übersetzung von Texten:

- Wann hört ein Satz auf?
- Wie groß ist er nach dem Übersetzen?
- Problemlösung: Tokenizer, jedoch auch eigene und neue Aufgabe

Pixelzugriff:

- Besitzt einen absehbaren Iterator
- $aktuelleSpalte + (GesamtzahlSpalten * aktuelleReihe) = wievielterPixel$
- oder auch: $d = Image.data(); d[wievielterPixel]$

Selbststehende Aufgabe aufteilen

Die zu untersuchenden Eigenschaften

- U ist die Menge der Ursprungspositionen im Speicher
- Z ist die Menge der Zielpositionen im Speicher
- F ist die Funktion, die U auf Z abbildet
- Die Größe und Position eines jeden einzelnen Elementes der Eingabemenge ist bekannt
- Die Größe und Position eines jeden einzelnen Elementes der Ausgabemenge ist bekannt
- Die Bearbeitungszeit eines Elementes

Weitere Eigenschaften

- Ist die Positionsänderung eines Pixels injektiv, wird jeder Pixel aus U genau einem Pixel aus Z zugewiesen.
- ist die Positionsänderung eines Pixel dagegen surjektiv, kann ein Pixel aus Z durch mehrere Pixel aus U beschrieben werden.

Zwischenerkenntnisse

Ist die Abbildungsfunktion der Position...

- injektiv, müssen nur ggfs. leere Positionen gefüllt werden.
- surjektiv, müssen Ergebnisse zur gleichen Zielposition in einem zusätzlichen Konstrukt vorgehalten werden. Werden die Eingabeelemente verändert, so müssen diese auch vor Veränderung geschützt werden, bis alles berechnet wurde (vgl. Game of Life)

Beispiel: Skalierung eines Bildes

Halbierung des Bildes wird verwendet um in einer geringeren Datenmenge Bereiche auszuschließen

- Pixel werden in einem n-Tupel gebündelt, wobei n eine endliche Zahl ist
- Beispiel: Wird ein Bild halbiert, wird ein 4-Tupel auf ein 1-Tupel abgebildet. Dabei werden 2x2 Pixel zu einem zusammengefasst

Bearbeitungszeit einzelner Elemente

- Für die Bearbeitung einzelner Elemente kann eine Laufzeitanalyse durchgeführt werden
- Wenn es mehr zu bearbeitende Elemente als gleichzeitig laufende Threads existieren, so muss man sich Gedanken über die Aufteilung machen

Amdahlsches Gesetz

Geschwindigkeitsgewinn eines parallelisierbaren Problems

Formelzeichen	bezeichnete Größe
T	Gesamtlaufzeit
t_s	Laufzeit eines seriellen Programmabschnitts
t_p	Laufzeit eines parallelen Programmabschnitts
n_p	Anzahl der nutzbaren Prozessoren
$t_{O(np)}$	Laufzeit für Synchronisierungsaufwand
n_s	Speedup-Faktor

$$n_s = \frac{T}{t_s + t_{O(np)} + \frac{t_p}{n_p}} \leq \frac{T}{t_s} = \frac{T}{T - t_p}$$

Amdahlsches Gesetz

- Die Funktion hat für jede Eingabe eine obere Schranke
- Kann 50% einer Aufgabe parallel zum restlichen Teil ausgeführt werden, ist die obere Schranke 2
- Das Gesetz gbit eine schnelle Einschätzung über den Geschwindigkeitsgewinn

Parallelisierung einer For-Schleife

- Ein absehbarer Iterator kann ich Chunks aufgeteilt werden
- $aktuelleSpalte + (GesamtzahlSpalten * aktuelleReihe) = wievielterPixel$
- Jeder Chunk bekommt einen Start- und Endindex, so wie das notwendige Inkrement
- Die entstanden Chunks können auf einen einzelne Threads aufgeteilt werden

Aufgabenteilung in Chunks

Geschwindigkeitsgewinn eines parallelisierbaren Problems

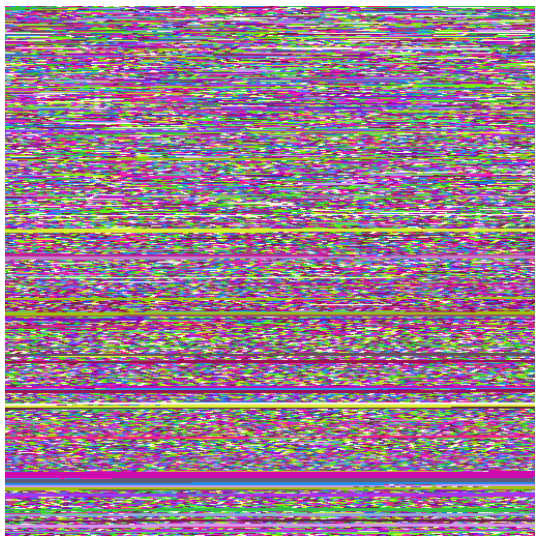

Chunkgröße 5 Pixel

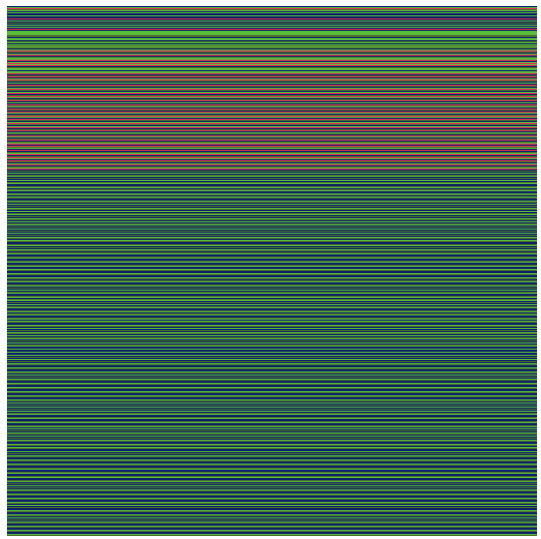

Chunkgröße Anzahl der Spalten

Aufgabenteilung in Chunks

Geschwindigkeitsgewinn eines parallelisierbaren Problems

Mandelbrot mit 2048x2048 Pixeln und 4 Threads

Art	Dauer in Sekunden	Speedup
Sequentiell	40,149	-
Breite*1	13,022	3,08
Breite*51	12,126	3,31

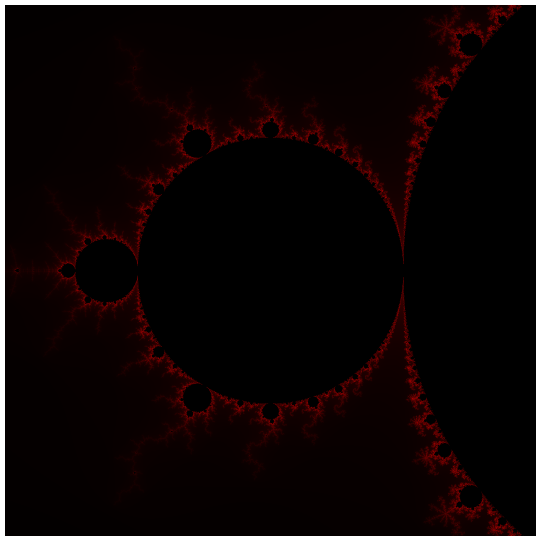

Threadpools

- Mehrere Threads werden in einem Objekt gekapselt
- Die Threads sind in einem wartenden Zustand, bis neue Aufgaben kommen
- Objectpooling reduziert den Initialisierungsaufwand
- Der Verwaltungsaufwand für Threads wird von der tatsächlichen Bearbeitung abgekapselt

Taskmanager ähnliches Konstrukt

kontrolliert eine begrenze Anzahl an Threads

- kontrolliertes Beenden des Programmes
- verhindert größere Auslastung als vorgegeben
- garantiert Bearbeitungszeit
- falls implementiert, umschalten zu sequentieller Bearbeitung (z.B. im Fehlerfall)

Literatur

- Operating System Concepts, Abraham Silberschatz
- OpenMP Complete Specifications Version 3.1 – Jul 2011
- Mikroprozessortechnik, Klaus Wüst
- Design Patterns, Erich Gamma
- C++ Primer, Stanley B.Lippman